

Cumarex — Documentation du pipeline ETL

Schema de la base de donnees, flux d'ingestion depuis les PDF, et relations entre tables


Ce document decrit l'ensemble du systeme d'ingestion Cumarex : les fichiers PDF sources, les extracteurs Python qui en tirent des donnees structurees, le pipeline (`pipeline_etl.py`) qui les transforme et les insere, et le schema PostgreSQL final avec toutes les relations entre tables.

Sommaire

- 1. Vue d'ensemble du flux
- 2. Tableau de correspondance PDF → extracteur → table(s)
- 3. Detail des tables, par domaine
 - 3.1 Referentiels (sites, articles, clients, poissons, postes)
 - 3.2 Production reelle & ecart de cout (par_article, C.Global)
 - 3.3 Main d'oeuvre directe — MOD (Mod S1 / Mod S2)
 - 3.4 Rendement / lots de matiere premiere
 - 3.5 Resume journalier de production
 - 3.6 Fiches techniques (standards) — non alimentee automatiquement

1. Vue d'ensemble du flux

Six fichiers PDF, produits quotidiennement par site, alimentent la base via six extracteurs Python dedies, puis les fonctions `run_etl_*` / `upsert_*` de `pipeline_etl.py`. L'ensemble tourne dans une transaction unique (`execute_etl()`) : soit tout est insere, soit rien ne l'est en cas d'erreur, pour garantir la coherence entre les differentes sources d'un meme jour.



2. Tableau de correspondance PDF → extracteur → table(s)

PDF source	Extracteur Python	Fonction pipeline	Table(s) PostgreSQL alimentee(s)
par_article_*.pdf (fiche "Couts Journaliers Productions", 1 fiche = 1 serie de fabrication)	ParArticleExtractor	run_etl_par_article()	articles (creation si nouveau code produit)
			productions_journalieres (1 ligne = 1 fiche/serie)
			ecarts_couts_postes (1 ligne par poste de cout : Poisson, Huile, Additif, Boite, MOD, MOMg, Fr Fab, Port, ...)
			postes_couts_reference (referentiel des libelles de poste de cout, cree a la volee)
C.Global.pdf	CoutGlobalExtractor	run_etl_par_article() (jointure sur le code produit)	Complete productions_journalieres (colonnes Tot CD / Tot MB / Tot PMV / Tot M.N / Tot PR) — aucune table dediee, pas de totaux_sites/total_general persistes
Rendement.pdf	RendementExtractor	upsert_lots_poisson()	lots_poisson (1 ligne par lot de matiere premiere entre au frigo)
Resume_*.pdf ("Couts Journaliers Production", vue agregee du jour)	ResumeExtractor	run_etl_resume()	resume_journalier (1 ligne par jour+site)
			matiere_premiere (CAOMA / CAMAT)
			mod_global (Mo, Mg, Mod/C, Mg/C)
			resume_production_poisson (resume "Caballa" etc.)
			table_codes (Egoutte/Casse/Huile/MOD/Mg/FrFabDh par code)
			couts_unitaires_code (cout unitaire agregé par article, 2e source independante)
Mod S1.pdf / Mod S2.pdf	ModExtractor (S1) ModExtractor_2 (S2)	upsert_mod_long_format()	postes_production (referentiel des 7 postes MOD, cree une fois)
			mod_durees_espece_poste + mod_communs_journaliers
—	Aucun extracteur fourni actuellement		fiches_techniques — non alimentee (voir section 3.6)

3. Detail des tables, par domaine

3.1 Referentiels

sites_production

Referentiel des sites (S1, S2). Normalise depuis les codes bruts "CX0"/"CX1" imprimes sur les PDF via `normalize_site_code()`.

Colonne	Type	Note
id_site PK	integer	
code_site	varchar(10)	"S1" / "S2" (normalise, jamais "CX0"/"CX1")
nom_site	varchar(100)	
localisation	varchar(100)	
actif	boolean	

clients

Marques/clients (Hacendado, ALIA, Delicius, SEASON, ...), deduites du champ "marque" de `par_article`.

Colonne	Type	Note
id_client PK	integer	
code_client	varchar(50)	
nom_client	varchar(100)	

types_poisson

Referentiel des especes (Caballa Merca, Sardine SPSA, Thon Rouge, ...).

Colonne	Type	Note
id_type_poisson PK	integer	
code_type	varchar(50)	
nom_type	varchar(100)	
famille	varchar(50)	

articles

Referentiel des codes produits (ex. 125FCOAHD). Cree par `upsert_article()` a la premiere rencontre dans `par_article`. Les autres extracteurs (`resume.py`) ne font que le RECHERCHER (jamais le creer), avec `repli` par prefixe car le code y est souvent tronque.

Colonne	Type	Note
id_article PK	integer	
code_article	varchar(20)	Code complet, non tronque (ex. "125MCDSTPME")
designation	varchar(200)	
id_type_poisson FK	integer	→ types_poisson
id_client FK	integer	→ clients
fiche_type	varchar(20)	default "RR-125A"
code_interne	varchar(50)	

postes_production

Referentiel STRICTEMENT reserve aux 7 postes MOD (ET, EMB, FIL, SRTI, PR_MP, NLE, COMM). TOT/TOT2 explicitement exclus.

Colonne	Type	Note
id_poste PK	integer	
code_poste	varchar(20)	ET/EMB/FIL/SRTI/PR_MP/NLE/COMM uniquement
categorie	varchar(50)	"production" ou "commun"

postes_couts_reference

Referentiel des lignes de cout des fiches `par_article` (Poisson, Huile, Additif, Boite, Etui-carton, MOD, MOMG, Fr Fab, Port, ...). Distinct de postes_production.

Colonne	Type	Note
id_poste_cout PK	integer	
code_poste_cout	varchar(20)	ex. "POISSON", "HUILE", "MOD"
nom_poste_cout	varchar(100)	

3.2 Production reelle & ecart de cout

productions_journalieres

1 ligne par fiche par_article (= 1 serie de fabrication), completee par les totaux de C.Global.

Colonne	Type	Note
id_production PK	integer	
date_production	date	= date_reception (par_article), coherente avec C.Global/Rendement
id_site FK	integer	→ sites_production
id_article FK	integer	→ articles
no_s_produit / no_poisson	varchar(20)	ordre de fabrication
poisson_kg / filet_kg / rdt_filet_pct	numeric	
px_mp / huile_kg / pu_huile / fr_fab / mod_total / momg / ch_fixes	numeric	champs du cartouche par_article
devise / taux_change	varchar / numeric	

ecarts_couts_postes

Le detail fin Reel / Std / Ecart, POSTE PAR POSTE, pour une production donnee. Vient directement du tableau "Reel/Std" de la fiche par_article.

Colonne	Type	Note
id_ecart PK	integer	
id_production FK	integer	→ productions_journalieres (CASCADE)
id_poste_cout FK	integer	→ postes_couts_reference
reel_unitaire / stnd_unitaire / ecart_unitaire / pct_ecart	numeric	
reel_total / stnd_total / ecart_total	numeric	

3.3 Main d'oeuvre directe (MOD)

mod_durees_espece_poste

Duree (min/kg) par jour, site, espece et poste MOD (ET/EMB/FIL/SRTI). Alimentee ligne par ligne depuis Mod S1.pdf / Mod S2.pdf.

Colonne	Type	Note
id_mod_detail PK	integer	
date_production	date	
id_site FK	integer	→ sites_production
id_type_poisson FK	integer	→ types_poisson
id_poste FK	integer	→ postes_production
duree_min_kg	numeric NOT NULL	Ligne omise (pas de NULL) si le poste n'existe pas pour cette espece

mod_communs_journaliers

Temps MOD communs, non affectes a une espece (PR_MP, NLE, COMM), par jour+site.

Colonne	Type	Note
id_mod_commun PK	integer	
date_production	date	
id_site FK	integer	→ sites_production
pr_mp / nle / comm	numeric	

3.4 Rendement / lots de matiere premiere

lots_poisson

1 ligne par lot de matiere premiere entre en frigo, issue de Rendement.pdf. La date_production vient de par_article (context_date), pas de l'extracteur lui-meme.

Colonne	Type	Note
id_lot PK	integer	
date_production	date NOT NULL	
id_site FK	integer	→ sites_production
no_lot	varchar(50)	= champ "br" (bulletin de reception)
date_entree / nb_jours_frigo / frigo / fournisseur / br	date / int / varchar	
poids_kg / poids_filets_kg / rdt_pct / pct_mrc	numeric	
id_type_poisson FK	integer	→ types_poisson
etat	varchar(20)	"Congele"/"Frais"

3.5 Resume journalier de production

Toutes les tables ci-dessous partagent la cle `id_resume` → `resume_journalier`, avec suppression en cascade. `couts_unitaires_code` et `couts_par_serie` sont une **2e source independante** du meme type d'information que `ecarts_couts_postes` (venant d'un calcul different, cote resume.py) — volontairement non fusionnees, pour permettre une reconciliation entre les deux sources.

resume_journalier

1 ligne par jour+site. Cle d'unicite reelle : `reference_jour` (pas encore de contrainte `UNIQUE` explicite en base).

Colonne	Type	Note
<code>id_resume</code> PK	integer	
<code>date_production</code>	date NOT NULL	
<code>reference_jour</code>	varchar(50) NOT NULL	ex. "2606031"
<code>id_site</code> FK	integer	→ <code>sites_production</code> (site fourni par l'appelant, pas extrait du PDF)

matiere_premiere

Lignes CAOMA/CAMAT (fournisseur, lot, prix, quantite) du jour.

Colonne	Type	Note
<code>id_matiere_premiere</code> PK	integer	
<code>id_resume</code> FK	integer	→ <code>resume_journalier</code> (CASCADE)
<code>fournisseur</code> / <code>partie</code> / <code>pu</code> / <code>qte</code>	varchar / numeric	

mod_global

Bloc "M O D" agrege du resume (Mo, Mg, Mod/C, Mg/C).

Colonne	Type	Note
<code>id_mod_global</code> PK	integer	
<code>id_resume</code> FK	integer	→ <code>resume_journalier</code> (CASCADE)
<code>mo</code> / <code>mg</code> / <code>mod_c</code> / <code>mg_c</code>	numeric	

resume_production_poisson

Resume "Poisson" (ligne "Caballa" etc.) du jour.

Colonne	Type	Note
<code>id_resume_production</code> PK	integer	
<code>id_resume</code> FK	integer	→ <code>resume_journalier</code> (CASCADE)
<code>id_type_poisson</code> FK	integer	→ <code>types_poisson</code>
<code>qte_poisson</code> / <code>qte_filet</code> / <code>rdt_pct</code> / <code>pu_moy</code> / <code>pct_jour</code>	numeric	

table_codes

Table Egoutte/Casse/Huile/MOD/Mg/FrFabDh par code produit.

Colonne	Type	Note
<code>id_code</code> PK	integer	
<code>id_resume</code> FK	integer	→ <code>resume_journalier</code> (CASCADE)
<code>id_article</code> FK	integer	→ <code>articles</code> (resolu par prefixe si code tronque)
<code>egoutte_std</code> / <code>egoutte_reel</code> / <code>pct_casse</code> / <code>huile_reel</code> / <code>huile_std</code> / <code>mod_reel</code> / <code>mod_std</code> / <code>mg_reel</code> / <code>mg_std</code> / <code>frfabdh_reel</code> / <code>frfabdh_std</code>	numeric	

couts_unitaires_code (ajoutee — migration_v11)

Cout unitaire agrege par article et par jour — 2e source independante du meme cout que `ecarts_couts_postes`.

Colonne	Type	Note
<code>id_cout_unitaire</code> PK	integer	
<code>id_resume</code> FK	integer	→ <code>resume_journalier</code>
<code>id_article</code> FK	integer	→ <code>articles</code>
<code>poisson</code> / <code>huile</code> / <code>boite</code> / <code>etui</code> / <code>mod</code> / <code>mg</code>	numeric	
<code>f_fab_reel</code> / <code>f_fab_std</code> / <code>f_fin</code> / <code>c_d</code> / <code>p_v</code> / <code>m_b</code> / <code>pct_mb</code> / <code>ch_f</code> / <code>pct_cf</code> / <code>m_n</code> / <code>pct_mn</code>	numeric	
Contrainte : <code>UNIQUE(id_resume, id_article)</code>		

Montants (pas des couts unitaires) par serie/article et par jour — 2e source independante.

Colonne	Type	Note
id_cout_serie FK	integer	
id_resume FK	integer	→ resume_journalier
id_article FK	integer	→ articles
serie	varchar(20)	Prefixe du jour (ex. "A26060"), pas un no de lot unique — sans risque ici car 1 article = 1 serie/jour max (confirme)
b_pdtes / poisson / boits / huile / etui / mod / mg	numeric	
f_fab_reel / f_fab_std / f_fin / c_d / mb / pct_mb / cf / mn / pct_mn	numeric	
Contrainte : UNIQUE(id_resume, id_article, serie)		

3.6 Fiches techniques (standards)

fiches_techniques

Table non alimentee par le pipeline actuel. Aucun des 6 extracteurs fournis ne produit ce type d'information (le standard officiel d'un article, independant de toute production journaliere, avec historique de versions). `ecarts_couts_postes.stnd_unitaire` couvre deja le besoin courant de comparaison reel/standard au jour le jour (le standard tel qu'imprime sur la fiche par_article ce jour precis). `fiches_techniques` ne serait utile que pour : (a) garder un historique de versions de recette dans le temps, ou (b) consulter/modifier un standard independamment d'une production existante. A alimenter manuellement si ce besoin se confirme, ou via un futur extracteur si une fiche technique dediee existe.

Colonne	Type	Note
id_fiche PK	integer	
id_article FK	integer	→ articles
version / date_validite	varchar / date	
std_poisson / std_huile / std_additif / std_boite / std_etui / std_mod / std_momg / std_frfab / std_port / std_gfin / std_com / std_cd / std_pmv / std_mb / std_pct_mb	numeric	Standards officiels par poste